

THỰC HÀNH

BÀI 2

Phân tích dữ liệu với Jupyter Notebook và thư viện Pandas

Dataset thực hành: banhang_thuchanh.xlsx

Dataset bài tập: sinhvien_baitap.xlsx

PHẦN A – HƯỚNG DẪN THỰC HÀNH TỪNG BƯỚC

Trong phần này, sinh viên sẽ thực hành toàn bộ quy trình phân tích dữ liệu từ đầu đến cuối trên bộ dữ liệu `banhang_thuchanh.xlsx` – gồm dữ liệu đơn hàng điện thoại với 83 bản ghi, 9 cột và một số lỗi dữ liệu cố ý (giá trị thiếu, trùng lặp). Sinh viên làm theo từng bước theo thứ tự.

Bước 1 – Thiết lập môi trường và đọc dữ liệu

1.1 Tạo notebook mới

Mở Anaconda Prompt, di chuyển đến thư mục chứa file Excel và khởi động Jupyter:

```
cd D:\ThucHanh\Bai2
jupyter notebook
```

Trong Dashboard, nhấn New > Python 3 để tạo notebook mới. Đổi tên thành `bai2_banhang.ipynb`.

Lưu ý: Đặt file `banhang_thuchanh.xlsx` trong cùng thư mục với notebook để sử dụng đường dẫn tương đối.

1.2 Import thư viện

Ở cell đầu tiên, nhập lệnh import toàn bộ thư viện cần dùng và chạy bằng Shift+Enter:

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

print('Pandas version:', pd.__version__)
```

Kết quả mong đợi: in ra phiên bản Pandas (ví dụ: Pandas version: 2.1.0).

1.3 Đọc dữ liệu từ Excel

Đọc sheet `DuLieu` từ file Excel vào DataFrame:

```
df = pd.read_excel('banhang_thuchanh.xlsx', sheet_name='DuLieu')
df.head()
```

Mẹo: Nếu thấy lỗi `FileNotFoundError`, hãy kiểm tra lại thư mục đang chạy notebook bằng lệnh: `import os; print(os.getcwd())`

1.4 Khám phá cấu trúc dữ liệu

Chạy lần lượt từng cell dưới đây để hiểu cấu trúc bộ dữ liệu:

```
# Số hàng và số cột
print('Shape:', df.shape)
```

```
# Kiểu dữ liệu từng cột
df.dtypes
```

```
# Thông tin tổng hợp (quan trọng nhất)
df.info()
```

```
# Xem 5 hàng đầu
df.head()
```

```
# Xem 5 hàng cuối
```

```
df.tail()
```

```
# Xem 5 hàng ngẫu nhiên (chạy lại nhiều lần để khám phá)
df.sample(5)
```

Lưu ý: Nhìn vào kết quả `df.info()`, xác định cột nào có số Non-Null nhỏ hơn tổng số hàng – đó là cột có giá trị thiếu.

Bước 2 – Phát hiện và làm sạch dữ liệu

2.1 Phát hiện giá trị thiếu

```
# Đếm giá trị thiếu theo từng cột
missing = df.isna().sum()
print(missing)

# Tỷ lệ thiếu (%)
print('\nTỷ lệ thiếu (%):')
print((df.isna().sum() / len(df) * 100).round(1))
```

Kết quả mong đợi: cột `hang`, `don_gia` và `danh_gia_kh` có một số giá trị NaN.

2.2 Xử lý giá trị thiếu

Áp dụng chiến lược phù hợp cho từng cột:

```
# Cột 'hang': điền bằng 'Không rõ' (không có giá trị trung bình để điền)
df['hang'] = df['hang'].fillna('Khong ro')

# Cột 'don_gia': điền bằng giá trị trung vị (bền hơn mean khi có outlier)
df['don_gia'] = df['don_gia'].fillna(df['don_gia'].median())

# Cột 'danh_gia_kh': điền bằng giá trị trung bình
df['danh_gia_kh'] = df['danh_gia_kh'].fillna(df['danh_gia_kh'].mean().round(1))

# Kiểm tra lại – kết quả phải là 0 tất cả các cột
print(df.isna().sum())
```

Lưu ý: Sau khi xử lý, `df.isna().sum()` phải trả về 0 cho tất cả các cột. Nếu còn NaN, kiểm tra lại tên cột đã đúng chưa.

2.3 Xử lý dữ liệu trùng lặp

```
# Phát hiện số dòng trùng lặp
dup_count = df.duplicated().sum()
print(f'Số bản ghi trùng: {dup_count}')

# Xem các bản ghi trùng
df[df.duplicated()]

# Loại bỏ trùng lặp (giữ bản đầu tiên)
df = df.drop_duplicates()
print(f'Số hàng sau khi xoá trùng: {len(df)}')
```

2.4 Chuẩn hoá dữ liệu chuỗi

Kiểm tra và chuẩn hoá cột `ku_vuc` và `nhân_vien` để tránh lỗi do khoảng trắng thừa:

```
# Xem các giá trị duy nhất
```

```
print('Khu vực:', df['khu_vuc'].unique())
print('Nhân viên:', df['nhan_vien'].unique())

# Chuẩn hoá: bỏ khoảng trắng đầu/cuối
df['khu_vuc'] = df['khu_vuc'].str.strip()
df['nhan_vien'] = df['nhan_vien'].str.strip()
```

2.5 Tạo cột mới từ dữ liệu hiện có

```
# Tạo cột doanh_thu = so_luong * don_gia
df['doanh_thu'] = df['so_luong'] * df['don_gia']

# Chuyển cột ngay_dat về kiểu datetime
df['ngay_dat'] = pd.to_datetime(df['ngay_dat'])

# Trích xuất tháng từ ngày
df['thang'] = df['ngay_dat'].dt.month

# Kiểm tra kết quả
df[['order_id', 'ngay_dat', 'thang', 'doanh_thu']].head(5)
```

2.6 Lưu dữ liệu đã làm sạch

```
# Lưu ra file CSV (không lưu index)
df.to_csv('banhang_clean.csv', index=False, encoding='utf-8-sig')
print('Đã lưu file banhang_clean.csv')
```

Mẹo: Dùng encoding='utf-8-sig' khi lưu CSV có tiếng Việt để mở đúng trong Excel không bị lỗi font.

Bước 3 – Thống kê mô tả

3.1 Tổng quan với df.describe()

```
# Thống kê cho tất cả cột số
df.describe()
```

```
# Thống kê riêng cột doanh_thu
print('Tổng doanh thu: ', df['doanh_thu'].sum())
print('Trung bình DT: ', round(df['doanh_thu'].mean(), 0))
print('Trung vị DT: ', df['doanh_thu'].median())
print('Độ lệch chuẩn: ', round(df['doanh_thu'].std(), 0))
print('Đơn hàng lớn nhất:', df['doanh_thu'].max())
```

3.2 Phân tích tần suất biến phân loại

```
# Số sản phẩm khác nhau
print('Số loại sản phẩm:', df['san_pham'].nunique())

# Tần suất theo khu vực
print('\nSố đơn hàng theo khu vực:')
print(df['khu_vuc'].value_counts())

# Tỷ lệ % theo hãng
print('\nTỷ lệ đơn hàng theo hãng (%):')
print(df['hang'].value_counts(normalize=True).mul(100).round(1))
```

3.3 Ma trận tương quan

```
# Tính tương quan giữa các cột số
corr = df[['so_luong', 'don_gia', 'danh_gia_kh', 'doanh_thu']].corr()
print(corr.round(2))
```

Bước 4 – Nhóm dữ liệu và tổng hợp

4.1 Doanh thu theo khu vực

```
dt_vung = df.groupby('khu_vuc')['doanh_thu'].agg(
    tong_dt='sum',
    trung_binh_dt='mean',
    so_don='count'
)
dt_vung['trung_binh_dt'] = dt_vung['trung_binh_dt'].round(0)
print(dt_vung.sort_values('tong_dt', ascending=False))
```

4.2 Doanh thu theo nhân viên và hãng

```
# Tổng doanh thu theo nhân viên
dt_nv = df.groupby('nhan_vien')['doanh_thu'].sum().sort_values(ascending=False)
print('Doanh thu theo nhân viên:')
print(dt_nv)

# Pivot: doanh thu theo khu vực và hãng
pivot = pd.pivot_table(
    df,
    values='doanh_thu',
    index='khu_vuc',
    columns='hang',
    aggfunc='sum',
    fill_value=0
)
print('\nPivot Table - Doanh thu theo khu vực và hãng:')
print(pivot)
```

4.3 Doanh thu theo tháng

```
dt_thang = df.groupby('thang')['doanh_thu'].sum()
print('Doanh thu theo tháng:')
print(dt_thang)
```

Bước 5 – Trực quan hoá dữ liệu

5.1 Biểu đồ cột – Doanh thu theo khu vực

```
fig, ax = plt.subplots(figsize=(8, 5))

dt_theo_vung =
df.groupby('khu_vuc')['doanh_thu'].sum().sort_values(ascending=False)
ax.bar(dt_theo_vung.index, dt_theo_vung.values, color='#1F497D')

ax.set_title('Tổng doanh thu theo khu vực', fontsize=14, pad=12)
ax.set_xlabel('Khu vực', fontsize=11)
```

```

ax.set_ylabel('Doanh thu (VND)', fontsize=11)
ax.tick_params(axis='x', rotation=15)
ax.grid(axis='y', alpha=0.4)

plt.tight_layout()
plt.savefig('bieu_do_doanh_thu_vung.png', dpi=150, bbox_inches='tight')
plt.show()

```

5.2 Biểu đồ đường – Doanh thu theo tháng

```

fig, ax = plt.subplots(figsize=(8, 5))

ax.plot(dt_thang.index, dt_thang.values, marker='o', linewidth=2, color='#375623')
ax.fill_between(dt_thang.index, dt_thang.values, alpha=0.15, color='#375623')

ax.set_title('Xu hướng doanh thu theo tháng (2024)', fontsize=14, pad=12)
ax.set_xlabel('Tháng', fontsize=11)
ax.set_ylabel('Doanh thu (VND)', fontsize=11)
ax.set_xticks(range(1, 7))
ax.grid(True, alpha=0.4)

plt.tight_layout()
plt.savefig('bieu_do_xu_huong_thang.png', dpi=150, bbox_inches='tight')
plt.show()

```

5.3 Histogram – Phân phối đánh giá khách hàng

```

sns.set_theme(style='whitegrid')

fig, ax = plt.subplots(figsize=(7, 4))
sns.histplot(data=df, x='danh_gia_kh', bins=10, kde=True, color='#843C0C', ax=ax)

ax.set_title('Phân phối đánh giá khách hàng', fontsize=13)
ax.set_xlabel('Điểm đánh giá', fontsize=11)
ax.set_ylabel('Số lượng', fontsize=11)

plt.tight_layout()
plt.show()

```

5.4 Heatmap – Ma trận tương quan

```

corr = df[['so_luong', 'don_gia', 'danh_gia_kh', 'doanh_thu']].corr()

plt.figure(figsize=(6, 5))
sns.heatmap(corr, annot=True, fmt='.2f', cmap='coolwarm', center=0,
            linewidths=0.5, square=True)
plt.title('Ma trận tương quan', fontsize=13)
plt.tight_layout()
plt.show()

```

Bước 6 – Xuất kết quả phân tích

Sau khi hoàn thành phân tích, xuất kết quả ra file Excel với nhiều sheet:

```

# Tạo bảng tóm tắt theo khu vực
tom_tat_vung = df.groupby('khu_vuc').agg(
    so_don=('order_id', 'count'),

```

```

    tong_dt=('doanh_thu', 'sum'),
    tb_dt=('doanh_thu', 'mean'),
    tb_danh_gia=('danh_gia_kh', 'mean')
).round(0)

# Tạo bảng tóm tắt theo nhân viên
tom_tat_nv = df.groupby('nhan_vien').agg(
    so_don=('order_id', 'count'),
    tong_dt=('doanh_thu', 'sum'),
    tb_don=('doanh_thu', 'mean')
).round(0)

# Xuất ra Excel với nhiều sheet
with pd.ExcelWriter('ket_qua_phan_tich.xlsx') as writer:
    df.to_excel(writer, sheet_name='DuLieu_Sach', index=False)
    tom_tat_vung.to_excel(writer, sheet_name='TomTat_KhuVuc')
    tom_tat_nv.to_excel(writer, sheet_name='TomTat_NhanVien')
    dt_thang.to_excel(writer, sheet_name='DoanhThu_Thang', header=['doanh_thu'])

print('Đã xuất: ket_qua_phan_tich.xlsx')

```

Lưu ý: File `ket_qua_phan_tich.xlsx` sẽ có 4 sheet: dữ liệu đã làm sạch, tóm tắt theo khu vực, theo nhân viên, và theo tháng.

PHẦN B – BÀI TẬP TỰ LÀM

Dataset: sinhvien_baitap.xlsx

Yêu cầu chung: Sinh viên thực hiện toàn bộ bài tập dưới đây trên file sinhvien_baitap.xlsx (gồm 102 bản ghi kết quả học tập sinh viên). Tạo notebook mới tên bai2_sinhvien.ipynb, thực hiện từng yêu cầu theo thứ tự, viết Markdown cell giải thích trước mỗi bước, sau đó nộp file notebook .ipynb.

Yêu cầu 1 – Đọc và khám phá dữ liệu

- Đọc sheet KetQuaHocTap từ file sinhvien_baitap.xlsx vào DataFrame tên df_sv.
- Dùng df_sv.info(), df_sv.describe() và df_sv.head(10) để khám phá cấu trúc dữ liệu.
- Xác định và in ra: tổng số hàng, tổng số cột, danh sách tên cột và kiểu dữ liệu mỗi cột.
- Phát hiện giá trị thiếu: in ra số lượng NaN theo từng cột và tỷ lệ % thiếu.
- Phát hiện bản ghi trùng: in ra số lượng dòng trùng lặp và xem các dòng đó.

Yêu cầu 2 – Làm sạch dữ liệu

- Xử lý giá trị thiếu ở cột diem_giua_ky: điền bằng giá trị trung vị của cột đó.
- Xử lý giá trị thiếu ở cột xep_loai: điền lại bằng cách tính từ diem_tong_ket (xem bảng quy tắc trong sheet GhiChu).
- Xử lý giá trị thiếu ở cột nam_hoc: điền bằng giá trị xuất hiện nhiều nhất (mode).
- Loại bỏ toàn bộ bản ghi trùng lặp. In ra số hàng trước và sau khi xóa.
- Kiểm tra lại: in df_sv.isna().sum() – tất cả phải bằng 0.

Yêu cầu 3 – Biến đổi dữ liệu

- Tạo cột mới diem_trung_binh = (diem_giua_ky + diem_cuoi_ky) / 2, làm tròn 1 chữ số thập phân.
- Tạo cột mới da_dong_phi_text: nếu hoc_phi_da_dong là True thì 'Da dong', False thì 'Chua dong'.
- Chuẩn hoá cột khoa: dùng .str.strip().str.title() để đảm bảo viết hoa chữ đầu đồng đều.
- Đổi tên cột diem_tong_ket thành diem_chinh_thuc.
- Lưu DataFrame đã làm sạch ra file sinhvien_clean.csv (không lưu index, encoding utf-8-sig).

Yêu cầu 4 – Thống kê mô tả

- In ra thống kê mô tả đầy đủ (describe) cho các cột số.
- Tính và in ra: điểm tổng kết trung bình, trung vị, cao nhất, thấp nhất, độ lệch chuẩn.
- Đếm số sinh viên theo từng xep_loai và in tỷ lệ % (dùng value_counts với normalize=True).
- Đếm số sinh viên theo từng khoa.
- Tính ma trận tương quan giữa diem_giua_ky, diem_cuoi_ky, diem_chinh_thuc.

Yêu cầu 5 – Nhóm và tổng hợp dữ liệu

- Tính điểm trung bình tổng kết theo từng khoa (groupby + mean), sắp xếp giảm dần.
- Tính điểm trung bình theo từng nam_hoc.
- Tạo pivot table: index là khoa, columns là nam_hoc, values là diem_chinh_thuc, aggfunc là mean, làm tròn 2 chữ số.
- Tìm sinh viên có điểm tổng kết cao nhất và thấp nhất (dùng .idxmax() và .idxmin()).
- Đếm số sinh viên chưa đóng học phí theo từng khoa.

Yêu cầu 6 – Trực quan hoá

- Vẽ biểu đồ cột nằm ngang (kind='barh') thể hiện điểm trung bình theo khoa. Thêm tiêu đề, nhãn trục, lưới.
- Vẽ histogram phân phối điểm tổng kết với đường KDE (dùng sns.histplot với kde=True).
- Vẽ boxplot so sánh phân phối điểm cuối kỳ theo xep_loai (dùng sns.boxplot).
- Vẽ heatmap ma trận tương quan giữa các cột điểm (dùng sns.heatmap với annot=True).
- Lưu ít nhất một biểu đồ ra file .png bằng plt.savefig().

Yêu cầu 7 – Xuất kết quả

- Tạo bảng tóm tắt theo khoa (số SV, điểm TB, điểm cao nhất, điểm thấp nhất) bằng .agg().
- Xuất file Excel ket_qua_sinhvien.xlsx gồm 3 sheet: DuLieu_Sach, TomTat_Khoa, TomTat_NamHoc.

Tiêu chí đánh giá

Bài tập được chấm theo bảng tiêu chí dưới đây. Tổng cộng 10 điểm.

Yêu cầu	Nội dung	Điểm
Yêu cầu 1	Đọc và khám phá dữ liệu đúng, in đủ thông tin	1.0
Yêu cầu 2	Làm sạch đúng: NaN = 0, loại bỏ trùng lặp	1.5
Yêu cầu 3	Biến đổi dữ liệu chính xác, có Markdown giải thích	1.5
Yêu cầu 4	Thống kê mô tả đầy đủ, kết quả đúng	1.5
Yêu cầu 5	Nhóm và tổng hợp đúng, pivot table hiển thị được	2.0
Yêu cầu 6	Ít nhất 4 biểu đồ, có tiêu đề và nhãn đầy đủ	2.0
Yêu cầu 7	File Excel kết quả đúng cấu trúc	0.5
Trình bày	Notebook có Markdown cell giải thích, code sạch, không có cell lỗi khi chạy lại	Cộng thêm 1.0

Lưu ý: Notebook phải chạy được hoàn toàn từ đầu đến cuối khi dùng Kernel > Restart & Run All. Notebook có cell báo lỗi sẽ bị trừ điểm tương ứng.

Gợi ý tham khảo

Dưới đây là một số hàm và kỹ thuật quan trọng cần nhớ cho bài tập này:

```
# Điền xep_loai dựa trên diem_chinh_thuc
def tinh_xep_loai(diem):
    if diem >= 8.5: return 'Xuat sac'
    elif diem >= 7.0: return 'Gioi'
    elif diem >= 5.5: return 'Kha'
    elif diem >= 4.0: return 'Trung binh'
    else: return 'Yeu'

# Chỉ điền những ô đang là NaN
mask = df_sv['xep_loai'].isna()
df_sv.loc[mask, 'xep_loai'] = df_sv.loc[mask,
'diem_tong_ket'].apply(tinh_xep_loai)
```

```
# Tìm sinh viên điểm cao nhất
idx_max = df_sv['diem_chinh_thuc'].idxmax()
print(df_sv.loc[idx_max])
```

```
# Đếm sinh viên chưa đóng học phí theo khoa
chua_dong = df_sv[df_sv['hoc_phi_da_dong'] == False]
print(chua_dong.groupby('khoa').size())
```

```
# Biểu đồ cột nằm ngang
diem_theo_khoa = df_sv.groupby('khoa')['diem_chinh_thuc'].mean().sort_values()
diem_theo_khoa.plot(kind='barh', figsize=(8, 5), color='#375623')
plt.xlabel('Điểm trung bình', fontsize=11)
plt.title('Điểm tổng kết trung bình theo khoa', fontsize=13)
plt.tight_layout()
plt.show()
```